



## 赖哲剑

联系电话: (+86)19979869426

Email: [laizj@smail.nju.edu.cn](mailto:laizj@smail.nju.edu.cn)

个人主页: [resume.laizj.fun](http://resume.laizj.fun)

## 教育经历

|                      |             |                          |             |
|----------------------|-------------|--------------------------|-------------|
| 大连理工大学 网络工程          | 2019-2023   |                          |             |
| 南京大学 计算机科学与技术        | 2023至今      |                          |             |
| 本科专业排名: 1.68%, 2/119 | GPA: 4.27/5 | CCF 认证分数: 290(5%)        | 英语六级成绩: 503 |
| 硕士实验室: 南京大学自然语言处理实验室 | 导师: 黄书剑     | 研究方向: 合成数据&大模型推理&跨语言知识学习 |             |

## 竞赛经历

- WMT2023 Quality Estimation Shared Tasks in En-De: First Place 2023
- 中国高校计算机大赛 (CCCC): 国家级个人二等奖 2021
- 第二届全国大学生算法设计与编程挑战赛 (秋季赛): 银牌 2020
- 第十二届全国大学生数学竞赛 (非数学专业): 二等奖 2020
- 第一届辽宁省大学生程序设计竞赛: 金牌 2020

## 科研经历

### *Making Mathematical Reasoning Adaptive*

<https://arxiv.org/abs/2510.04617> || 共同一作, ICLR 2026 在投 || 2025.3 - 2025.9

**研究内容:** 围绕大模型数学推理的鲁棒性与泛化难题, 我们将错误源归因于依赖表面特征的“虚假推理”, 提出鼓励对不同变量取值自适应的推理范式。为了使得模型学会“自适应推理”, 我们设计了 AdaR: 在提取出一个问题的问题模板与对应的解题代码后, 通过改变变量取值合成逻辑等价题目, 并以代码求得可靠答案, 最后经过合法性检查得到题目答案对; 合成数据结合 RLVR 后会提供更可靠的奖励进而惩罚虚假推理、鼓励自适应推理。实验结果显示, 少量数据条件下, AdaR 在鲁棒性与泛化性任务上均显著提升性能; 分析表明该方法促使模型习得代数思维, 具备可扩展性与广泛适用性。

**主要贡献:** 主导设计了AdaR框架的整体研究方案 (包括问题模版与解题代码的对应思想, 可控性扰动, 合法性检查方案, 搭配RLVR利用合成数据等) 并独立完成实现。负责了大部分分析实验的设计, 独立完成了所有实验内容。

### *How does Alignment Enhance LLMs' Multilingual Capabilities? A Language Neurons Perspective*

<https://arxiv.org/pdf/2505.21505.pdf> || 共同一作, AAAI 2026 在投 || 2024.10 - 2025.5

**研究内容:** 提出了一种更细粒度的神经元识别算法, 可检测语言神经元 (包括语言特定神经元和语言相关神经元) 及语言无关神经元。进一步地, 根据不同类型神经元的分布特征, 将大语言模型的多语言推理内部过程划分为四个部分: 1) 多语言理解; 2) 共享语义空间推理; 3) 多语言输出空间转换; 4) 词汇空间输出。此外, 我们系统分析了模型对齐前后各类神经元的变化, 并研究了“自发多语言对齐”现象。

**主要贡献:** 改进了神经元识别算法, 独立负责模型多语言对齐部分的复现, 参与提出了4阶段模型推理过程的猜想, 并设计并完成了部分分析实验。

### *Alleviating Distribution Shift in Synthetic Data for Machine Translation Quality Estimation*

<https://arxiv.org/pdf/2502.19941.pdf> || 共同一作, ACL 2025 Long Paper || 2023.12 - 2025.2

**研究内容:** 提出一种针对机器翻译质量评估任务的高效可解释伪数据增强方法, 通过充分利用参考语句提供的监督信号和模型间的多样性, 有效缓解了奖励模型中的分布偏移问题。实验表明, 该方法在有监督和无监督两个场景下均取得当前最优表现, 并以更轻量的模型规模超越了CometKiwi与GPT-4等主流强基线模型。此外, 通过系统性的分析实验, 提出了多种可以应用于缓解奖励模型 (如PRM) 分布偏移问题的策略, 包括增强模型多样性、强化监督信号利用率等。

**主要贡献:** 提出并实现了标注器与生成器的双模型伪数据生成框架。设计了一种基于句法依存树与最近公共祖先算法的新型标签聚合方法, 实现了标注结果与人类偏好的对齐。设计并开展了消融实验与深入的分析性实验。独立实现了所有实验内容的代码。

### *Unify word-level and span-level tasks: NJUNLP's participation for the WMT2023 quality estimation shared task*

<https://arxiv.org/pdf/2309.13230.pdf> || 二作, WMT2023 Shared Task Paper || 2023.7 - 2023.11

**研究内容:** 提出一种针对机器翻译质量评估任务的高效可解释伪数据增强方法, 基于验证集中机器翻译错误的长度、位置和严重程度分布, 对平行语料中的参考句子进行规则引导下的扰动, 以生成可解释性伪数据。然后通过预训练+多任务微调的二阶段训练策略获得最终模型。比赛结果显示我们在英德语言方向的所有子任务上均取得了第一名的成绩。

**主要贡献:** 设计了基于规则引导的伪数据的生成框架。独立实现了关于伪数据生成和模型预训练的代码并完成对应实验。

### **Improved pseudo data for machine translation quality estimation with constrained beam search**

<https://aclanthology.org/2023.emnlp-main.764.pdf> || 二作, EMNLP 2023 Long Paper || 2022.6 - 2023.6

**研究内容:** 提出一种基于约束束搜索的伪翻译生成方法, 通过参考语句的生成概率引导伪翻译结果, 以显著降低TER工具标记高假阳率样本的风险, 从而有效缓解机器翻译质量评估领域中HTER数据稀缺的问题。经实验验证, 该方法在有监督和无监督场景下均显著提升了模型性能。

**主要贡献:** 完成主实验测试, 并对相关主流对比方法进行复现与性能评测。针对所提出的约束束搜索算法, 完成了定量和定性实验检验其有效性, 并进一步开展了全面的消融实验, 探讨了算法中关键超参数和生成概率调整函数对整体性能提升的影响。独立实现了所有实验内容的代码。

---

### **荣誉奖励**

|                        |                       |
|------------------------|-----------------------|
| • 国家奖学金 ( 0.8% )       | 2020-2021 & 2021-2022 |
| • 学业奖学金 ( 一等 ) ( 5% )  | 2023-2024             |
| • 华为“智能基座”学生奖学金 ( 1% ) | 2022-2023             |

---